# 機器學習導論 - 期末報告

# Airbnb New User Bookings

巨資四 A 05170138 黃品嘉

巨資四 A 05170132 魏嗣宸

巨資四 A 05170120 王宇婕



# 目錄 Contents

_ `	資料描述 Data Descriptions3
_ `	資料預處理 Data Preprocessing4
$\equiv$ \	演算法測試 Test of Algorithm12
	• xgboost
	• logistic
	• decision tree
	• random forest
四、	演算法成績比較 Algorithm Comparison15
五、	結果 Conclusions17
<u></u>	參考資料 Reference18

## 一、資料型態描述 Data Descriptions

● id: 使用者 id

● date\_account\_created: 帳號建立的日期

• timestamp\_first\_active: 使用者第一次使用的時間

● date\_first\_booking: 使用者第一次訂房的時間

● gender: 使用者性別

● age: 使用者年齡

• signup\_method: 註冊方式

• signup\_flow: 註冊頁面

● language: 是用語言

● affiliate\_channel: 付費管道

● affiliate\_provider: 付費管道名稱

● first\_affiliate\_tracked: 註冊前,接觸的付費管道

● signup\_app: 註冊 APP

● first\_device\_type: 第一次使用的設備類別

• first\_browser: 第一次使用的瀏覽器

● country\_destination: 訂房目的地,此項為本次的目標

## 二、資料預處理 Data Preprocessing

#### 載入套件

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

#### 讀取檔案

```
train = pd.read_csv(r"C:\Users\user\data\train_users_2.csv",dtype={'date_first_bookin
g': str,'date_account_created': str,'timestamp_first_active':float})

test = pd.read_csv(r"C:\Users\user\data\test_users.csv",dtype={'date_first_booking':
    str,'date_account_created': str,'timestamp_first_active':float})

data = pd.concat([train , test] , axis = 0 , ignore_index=True)
```

設定 date\_first\_booking, date\_account\_created 為字串,

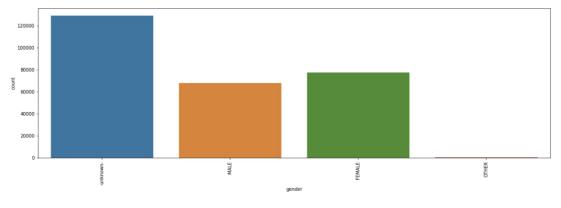
timestamp\_first\_active 為浮點數,合併成 data 檔。

#### 處理 Gender 資料

```
plt.figure(figsize=(20,6))
sns.countplot(data.gender)
plt.xticks(rotation=90)
```

#### 觀察發現-unknown-比例很高

(array([0, 1, 2, 3]),  $\langle$ a list of 4 Text xticklabel objects $\rangle$ )



```
data.gender.replace('-unknown-', np.nan, inplace=True)
print("New null value % in gender is: " + "{0:.2%}".format(sum(data.gender.isnull())/
data.shape[0]))
```

將-unknown-替換成空值,並檢視空值的比率為 46.99%

## 處理 age 資料

```
plt.figure(figsize=(20,6))
sns.countplot(data.age)
plt.xticks(rotation=90)
```

## 觀察 age 分佈,發現年齡範圍有超出合理範圍的值 Ex: 2014

```
(array([ 0,
13,
26,
39,
52,
65,
78,
91,
                                                                                                                                                     8, 9, 10, 11, 12, 21, 22, 23, 24, 25, 34, 35, 36, 37, 38, 47, 48, 49, 50, 51, 60, 61, 62, 63, 64, 73, 74, 75, 76, 77, 86, 87, 88, 89, 90, 99, 100, 101, 102, 103, 121, 112, 113, 114, 115
                                                                         16,
29,
42,
55,
68,
                                                                                                                                       20,
33,
46,
59,
72,
                                                         15,
28,
41,
54,
67,
80,
                                                                                        17,
30,
43,
                                                                                                       18,
31,
44,
                                                                                                                       19,
32,
45,
                                          14,
27,
40,
53,
66,
79,
92,
                                                                                         56,
69,
                                                                                                                       58,
71,
84,
97,
                                                                                                         57,
70,
                                                                          81,
94,
                                                                                         82,
95,
                                                                                                       83,
96,
                                                                                                                                       85,
98,
                         104, 105, 106, 107, 108, 109, 110, 111, 112, 113, 114, 115, 116, 117, 118, 119, 120, 121, 122, 123, 124, 125, 126, 127, 128, 129, 130, 131, 132, 133, 134, 135, 136, 137, 138, 139, 140, 141, 142, 143, 144]), ka list of 145 Text xticklabel objects)
```

```
data.loc[data.age < 18, 'age'] = np.nan
data.loc[data.age > 80, 'age'] = np.nan
data.age = data.age.replace("NaN", np.nan)
print("Now the % of null values in age is: " + "{0:.2%}".format(sum(data.age.isnull()))/data.shape[0]))
```

將 18 歲以下、80 歲以上視為錯誤資料→替換成空值,並檢視空值的比率為

43.64%

## 處理 signup\_flow 資料

```
data['signup_flow'] = data['signup_flow'].astype('object')
```

將 signup\_flow 轉成類別型態 (後會將資料轉成虛擬列 get\_dummies,故轉

成類別型態)

## 處理 affiliate\_channel 資料

```
data.affiliate_channel.value_counts()
  direct
            181571
                36439
 sem-brand
  sem-non-brand 20075
            14362
  seo
 other
             9547
            8167
  api
              4118
  content
                1268
 remarketing
data.affiliate_channel.replace('api', 'other', inplace=True)
data.affiliate_channel.replace('content', 'other', inplace=True)
data.affiliate_channel.replace('remarketing', 'other', inplace=True)
```

將數量較低的類別都歸類到 other

## 處理 affiliate\_provider 資料

```
data.affiliate_provider.value_counts()
 direct
               181270
                 65956
 google
 other
                13036
 facebook
                  3996
 bing
                3719
 craigslist
                 3475
 padmapper
                    836
 vast
                830
 yahoo
                 653
 facebook-open-graph
                        566
 gsp
                455
                   358
 meetup
                      270
 email-marketing
 naver
                  66
 baidu
                  32
 yandex
                  18
                  8
 wayn
 daum
                   3
```

```
data.affiliate_provider.replace('daum', 'other', inplace=True)
data.affiliate_provider.replace('wayn', 'other', inplace=True)
data.affiliate_provider.replace('yandex', 'other', inplace=True)
data.affiliate_provider.replace('baidu', 'other', inplace=True)
data.affiliate_provider.replace('naver', 'other', inplace=True)
data.affiliate_provider.replace('email-marketing', 'other', inplace=True)
data.affiliate_provider.replace('meetup', 'other', inplace=True)
.....
```

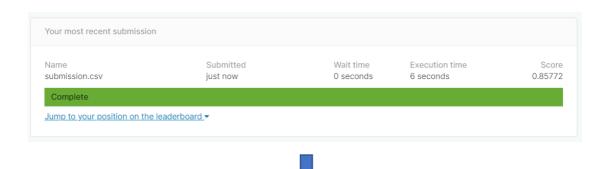
將數量較低的類別都歸類 other

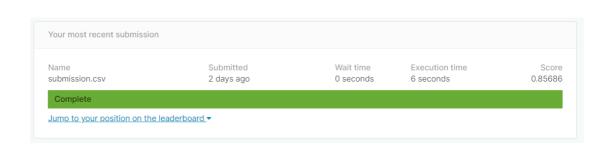
#### 處理 first browser 資料

```
data.first_browser.replace('IE Mobile', 'other', inplace=True)
data.first_browser.replace('AOL Explorer', 'other', inplace=True)
data.first_browser.replace('Android Browser', 'other', inplace=True)
data.first_browser.replace('Chrome Mobile', 'other', inplace=True)
data.first_browser.replace('Chromium', 'other', inplace=True)
data.first_browser.replace('BlackBerry Browser', 'other', inplace=True)
data.first_browser.replace('IE Mobile ', 'other', inplace=True)
data.first_browser.replace('Silk', 'other', inplace=True)
.....
```

#### 將數量較低的類別都歸類 other

affiliate\_channel、affiliate\_provider、first\_browser 將部分類別合併到
 other 是為了避免 get dommies 完後變成太多欄位,以致最後跑演算法負荷過重,但也不能取代過多,以免結果產生偏差。如下圖所示:





## one-hot-encoding-1

將部分類別資料轉成虛擬列

#### age 空值處理

```
from sklearn.linear_model import LogisticRegression
def set_missing_ages(df):
   columns = df[['age','affiliate_channel_direct',
       'affiliate_channel_other', 'affiliate_channel_sem-brand',
       'affiliate_channel_sem-non-brand','affiliate_channel_seo',
       'affiliate_channel_nan', 'affiliate_provider_bing',
       'affiliate_provider_craigslist',
        .....]]
# 分成已知年齡和未知年齡兩部分
   known_age = columns[columns.age.notnull()].as_matrix()
   unknown_age = columns[columns.age.isnull()].as_matrix()
   y = known_age[:, 0]
   X = known_age[:, 1:]
   lr=LogisticRegression()
   lr.fit(X, y)
   predictedages = lr.predict(unknown_age[:, 1:])
   df.loc[ (df.age.isnull()), 'age' ] = predictedages
   return df, lr
```

以邏輯式迴歸訓練已知年齡資料預測 age 的空值

## gender 空值處理

```
data.gender.replace('MALE', 0, inplace=True)
data.gender.replace('FEMALE', 1, inplace=True)
data.gender.replace('OTHER', 2, inplace=True)
```

先將文字轉成數值,方便後面跑演算法預測

以邏輯式迴歸訓練已知性別資料預測 gender 的空值

#### age 資料分類

```
bins=[17,25,35,45,55,65,81]
labels=['18-25','26-35','36-45','46-55','56-65','66-80',]
data['age']=pd.cut(data.age,bins,labels=labels)
```

將 age 分成 6 個階段 (數值轉類別)

#### timestamp\_first\_active 資料分類

將 timestamp\_first\_active 以年度及季節分成 25 個階段(數值轉類別, Ex:

```
0812-0902→冬)
```

#### 刪除欄位

```
data.drop(labels=['date_first_booking'],axis='columns',inplace=True)
data.drop(labels=['id'],axis='columns',inplace=True)
```

id 非特徵欄位; data\_first\_booking 在 test 檔中全為空值,因此這刪掉 2 欄位

## one-hot-encoding-2

## 目標欄位轉 label-encoding

```
y = train['country_destination'].values

from sklearn.preprocessing import LabelEncoder
labelencoder = LabelEncoder()
y = labelencoder.fit_transform(y)
```

#### 將要預測的國家轉成代碼

# 三、演算法測試 Test of Algorithm

切割 train, test 特徵欄位

```
X_train = data.values[:213451]
X_test = data.values[213451:]
```

test id 抓取

```
test_ids = test['id']
```

## 1. xgboost

#### 預測結果示意如下:

```
y_pred array([[0.00309393, 0.00504772, 0.00429806, ..., 0.00238365, 0.21934034,0.03065487],...... [0.00380462, 0.00760705, 0.0051426 , ..., 0.00231592, 0.37696147,0.04176515]], dtype=float32)
```

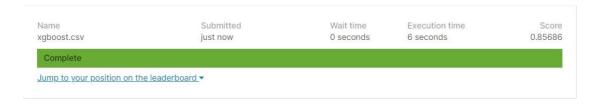
#### submission 存檔

```
ids = [] #list of ids
cts = [] #list of countries

for i in range(len(test_ids)):
    idx = test_ids[i]
    ids += [idx] *5
    cts += labelencoder.inverse_transform(np.argsort(y_pred[i])[::-1])[:5].tolist()

sub = pd.DataFrame(np.column_stack((ids, cts)), columns=['id', 'country'])
sub.to_csv('submission.csv',index=False)
```

#### kaggle 成績: 0.85686



## 2. logistic

```
lr=LogisticRegression()
lr.fit(X_train, y)
y_pred = lr.predict_proba(X_test)
```

kaggle 成績: 0.85467



#### 3. decision tree

## kaggle 成績: 0.85527



#### 4. random forest

```
from sklearn.ensemble import RandomForestClassifier

rf = RandomForestClassifier(n_estimators=300,criterion='gini')

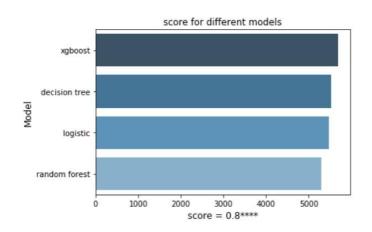
rf.fit(X_train,y)

y_pred = rf.predict_proba(X_test)
```

## kaggle 成績: 0.85299



## 四、演算法成績比較:



## ● 成績最好的為 **xgboost**

Boosting Tree 用 tree 來降低殘差,然後 xgboost 又引入二階導數 (二階泰勒展開式)進行求解,引入節點數和參數的 L2 正則性來評估模型的複雜性,並構造 xgboost 的預測和目標函數。

#### ● 優點:

- 1. 將樹形模型的複雜性(以正則項表示)添加到優化目標。
- 2. 在公式推導中使用二階導數,並使用二階泰勒展開式。
- 3. 實現了用於分割點查找的近似算法。
- 4. 利用特徵稀疏性。
- 5. 預先對數據進行排序並以塊形式存儲,這有利於並行計算。
- 6. 基於分佈式通訊框架 rabit,它可以在 MPI 和 yarn 上運行。
- 7. 針對架構優化了實現,針對緩存和內存優化了性能。

## ● xgboost 參數介紹

- 1. learning\_rate=0.3:用於更新葉子節點權重時,乘以該係數,避免步長過大,引數值越大,越可能無法收斂,把學習率 eta 設定的小一些,小學習率可以使得後面的學習更加仔細。
- 2. max\_depth = 6: 每顆樹的最大深度,樹高越深,越容易過擬合。
- 3. subsample=0.6:樣本隨機取樣,較低的值使得演算法更加保守,防止 過擬合,但是太小的值也會造成欠擬合。
- 4. **colsample\_bytree** = **0**.6:列取樣·對每棵樹的生成用的特徵進行列取樣。
- 5. **objective='multi:softprob'**:可以將該向量 reshape 成 ndata 行 nclass 列的矩陣。每行數據表示樣本所屬於每个類別的機率。
- 6. seed=0: 隨機數種子設為0。
- 7. n\_estimators=40:生成的最大樹數目

## 五、 結果 Conclusions

## ● xgboost 參數調整

## 1. max\_depth

 $max_depth 4 = 0.85592$ 

max\_depth 6 = 0.85686

max\_depth 8 = 0.85784

max\_depth 10 = 0.85788 → 雖然分數較高,但不明顯,而且跑演算法過

久,模型太複雜,不予取用。

## 2. learning\_rate

learning\_rate 0.4 = 0.85775

learning\_rate 0.3 = 0.85784

learning\_rate 0.2 = 0.85763

## 3. n\_estimators

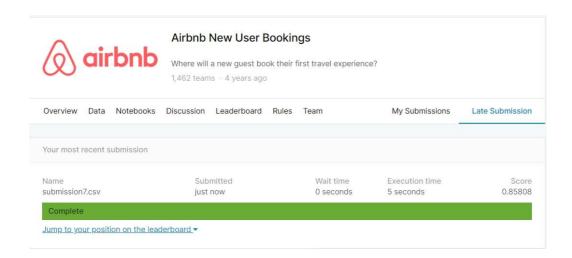
n\_estimators 50 = 0.85759

n\_estimators 40 = 0.85808

 $n_{estimators} 22 = 0.85784$ 

n\_estimators 12 = 0.85750

調整完參數後,成績從 0.85686 提升至 0.85808。



▶ 最終以 XGBoost 演算法在以下參數值訓練出成績最好的模型

## 六、參考資料 Reference

- 1. <a href="https://medium.com/@PatHuang/%E5%88%9D%E5%AD%B8python%E6%89%8B%E8%A8%98-3-">https://medium.com/@PatHuang/%E5%88%9D%E5%AD%B8python%E6%89%8B%E8%A8%98-3-</a>
  <a href="mailto:wE6%89%8B%E8%AB%8B8%E8%A8%98-3-">wE8%B3%87%E6%96%99%E5%89%8D%E8%99%95%E7%90%86-</a>
  <a href="mailto:label-encoding-one-hot-encoding-85c983d63f87">label-encoding-one-hot-encoding-85c983d63f87</a>
- 2. <a href="https://blog.csdn.net/Datawhale/article/details/80847662">https://blog.csdn.net/Datawhale/article/details/80847662</a>
- 3. https://zhuanlan.zhihu.com/p/28672955